

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

—o0o—

BÁO CÁO ĐỒ ÁN MÔN HỌC
HỌC SÂU (DEEP LEARNING)

Đồ án số: #20 – Phát hiện spam email

Sinh viên thực hiện: 23684961 - Tống Nguyễn Nhật Tiến
23689101 - Nguyễn Tiến Phát
Lớp: DHKHMT19BTT
Giảng viên hướng dẫn: TS. Lê Vũ Hạo

TP. Hồ Chí Minh, Ngày 06 tháng 05 năm 2026

Mục lục

1	Giới thiệu	5
1.1	Bối cảnh và động cơ	5
1.2	Mục tiêu đồ án	5
1.3	Phạm vi và cấu trúc báo cáo	6
2	Cơ sở lý thuyết và nghiên cứu liên quan	7
2.1	Kiến thức nền tảng	7
2.1.1	Word Embedding	7
2.1.2	Long Short-Term Memory (LSTM)	7
2.1.3	Bidirectional RNN	8
2.1.4	Transformer và Self-Attention	8
2.1.5	BERT (Bidirectional Encoder Representations from Transformers)	8
2.1.6	Mixture of Experts (MoE)	8
2.1.7	Các kỹ thuật Regularization	9
2.2	Các nghiên cứu liên quan	9
3	Bài toán và dữ liệu	10
3.1	Mô tả bài toán	10
3.2	Dataset	10
3.2.1	Nguồn dữ liệu	10
3.2.2	Tiền xử lý dữ liệu	12
4	Phương pháp đề xuất	13
4.1	Mô hình 1 – Baseline: BiLSTM + Embedding + Pooling	13
4.2	Mô hình 2 – Nâng cao: BERT MoE	14
4.3	Hàm mất mát và thuật toán tối ưu	15
4.3.1	Hàm mất mát	15
4.3.2	Thuật toán tối ưu	15
4.3.3	Callbacks và Scheduler	16
5	Thực nghiệm và đánh giá	17
5.1	Thiết lập thí nghiệm	17

5.2	Kết quả định lượng	18
5.2.1	Kết quả mô hình BiLSTM Baseline	18
5.2.2	Kết quả mô hình BERT MoE	18
5.2.3	Bảng so sánh tổng hợp	20
5.2.4	Biểu đồ so sánh tổng hợp	21
5.3	Phân tích kết quả	21
5.3.1	So sánh Optimizer: Adam/AdamW vs SGD	21
5.3.2	So sánh Regularization	21
5.3.3	So sánh Baseline vs Nâng cao	21
5.3.4	Phân tích lỗi điển hình	22
5.3.5	Giới hạn của mô hình	22
6	Kết luận và hướng phát triển	23
6.1	Kết luận	23
6.2	Hướng phát triển	23

Danh sách hình vẽ

3.1	Phân bố số lượng mẫu theo lớp Ham/Spam trong dataset	11
3.2	Phân bố độ dài văn bản theo số từ và Boxplot theo lớp	11
3.3	Pipeline tiền xử lý dữ liệu email	12
4.1	Kiến trúc mô hình 1 – BiLSTM Baseline	13
4.2	Kiến trúc mô hình 2 – BERT MoE (Nâng cao)	14
5.1	So sánh kết quả 3 thí nghiệm BiLSTM Baseline	18
5.2	Confusion Matrix và Precision-Recall Curve – BiLSTM (Adam + Dropout) . .	18
5.3	Confusion Matrix các thí nghiệm BiLSTM còn lại	18
5.4	BERT MoE – Confusion Matrix trước khi huấn luyện	19
5.5	BERT MoE (AdamW + Weighted Loss) – Kết quả tốt nhất	19
5.6	Learning Curves – BERT MoE (AdamW + Weighted Loss)	20
5.7	Confusion Matrix các thí nghiệm BERT MoE còn lại	20
5.8	Biểu đồ so sánh tổng hợp và Radar chart – tất cả mô hình	21
5.9	Phân tích lỗi: phân bố xác suất dự đoán và so sánh FP/FN giữa BiLSTM vs BERT MoE	22

Danh sách bảng

3.1	Thông tin tổng quan dataset	10
3.2	Phân chia tập dữ liệu (stratified split)	12
5.1	Thiết lập thí nghiệm	17
5.2	So sánh kết quả tất cả các mô hình và thí nghiệm	20

Chương 1

Giới thiệu

1.1 Bối cảnh và động cơ

Trong kỷ nguyên số hóa, email vẫn là một trong những phương tiện giao tiếp quan trọng nhất trong cả môi trường doanh nghiệp lẫn cá nhân. Theo thống kê, hàng ngày có khoảng 300 tỷ email được gửi đi trên toàn cầu, trong đó gần 45–50% là thư rác (spam). Spam email không chỉ gây phiền toái mà còn tiềm ẩn nhiều rủi ro bảo mật nghiêm trọng: lừa đảo tài chính (phishing), phát tán mã độc (malware), đánh cắp thông tin cá nhân và chiếm đoạt tài khoản.

Các phương pháp lọc spam truyền thống dựa trên quy tắc (rule-based) hoặc học máy cổ điển (Naive Bayes, SVM) đã bộc lộ nhiều hạn chế khi đối mặt với các kỹ thuật spam ngày càng tinh vi. Spam hiện đại sử dụng nhiều chiến thuật né tránh: biến đổi từ ngữ, chèn mã HTML phức tạp, sử dụng hình ảnh thay vì văn bản, và mạo danh các tổ chức uy tín.

Deep Learning, với khả năng tự động học các đặc trưng phức tạp từ dữ liệu văn bản, mang đến một hướng tiếp cận mạnh mẽ hơn cho bài toán phân loại spam. Đặc biệt, sự phát triển của mô hình Transformer và các biến thể như BERT đã tạo ra bước đột phá trong xử lý ngôn ngữ tự nhiên, cho phép nắm bắt ngữ cảnh toàn cục của văn bản hiệu quả hơn so với các mô hình sequence truyền thống.

1.2 Mục tiêu đề án

Đề án hướng đến việc đạt được các mục tiêu sau:

- **Phân tích và thiết kế:** Phân tích bài toán phân loại nhị phân spam/ham, nhận diện các thách thức đặc thù của dữ liệu email (HTML tags, ký tự đặc biệt, mất cân bằng lớp), và lựa chọn kiến trúc Deep Learning phù hợp.
- **Triển khai và thực nghiệm:** Triển khai đầy đủ pipeline huấn luyện bao gồm tiền xử lý dữ liệu, xây dựng và huấn luyện ít nhất hai mô hình – BiLSTM (baseline) và BERT MoE (nâng cao), so sánh các cấu hình optimizer và regularization.

- **Đánh giá và vận dụng:** Đánh giá kết quả bằng các metric phù hợp (Precision, Recall, F1-Score), phân tích lỗi điển hình, thảo luận giới hạn mô hình và đề xuất hướng cải tiến.

1.3 Phạm vi và cấu trúc báo cáo

Phạm vi đồ án:

- Sử dụng dataset Enron Spam (`spam_ham_dataset.csv`) với 5.170 mẫu email.
- Triển khai hai mô hình: BiLSTM (baseline) và BERT MoE (nâng cao) dựa trên kiến trúc BERT kết hợp Mixture of Experts.
- Thực hiện 6 thí nghiệm so sánh optimizer (Adam/AdamW vs SGD) và regularization (Dropout vs Weight Decay vs Frozen Encoder).
- Xây dựng hệ thống demo phân loại email real-time với ensemble BiLSTM + BERT MoE.

Cấu trúc báo cáo:

- **Chương 1:** Giới thiệu bối cảnh, mục tiêu và phạm vi.
- **Chương 2:** Cơ sở lý thuyết về các kiến trúc Deep Learning, BERT và Mixture of Experts.
- **Chương 3:** Mô tả bài toán, dataset và tiền xử lý dữ liệu.
- **Chương 4:** Phương pháp đề xuất – kiến trúc hai mô hình.
- **Chương 5:** Thực nghiệm, kết quả và phân tích.
- **Chương 6:** Kết luận và hướng phát triển.

Chương 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Kiến thức nền tảng

2.1.1 Word Embedding

Word Embedding là kỹ thuật biểu diễn từ vựng dưới dạng vector số thực trong không gian nhiều chiều. Thay vì sử dụng biểu diễn one-hot encoding (thừa và không chứa thông tin ngữ nghĩa), embedding layer học được các biểu diễn dày đặc (dense) trong quá trình huấn luyện.

Cho vocabulary V với $|V|$ từ, embedding layer ánh xạ mỗi từ w_i thành vector $e_i \in \mathbb{R}^d$:

$$e_i = E \cdot \text{one_hot}(w_i), \quad E \in \mathbb{R}^{d \times |V|} \quad (2.1)$$

trong đó d là kích thước embedding (trong đồ án này $d = 128$ cho BiLSTM).

2.1.2 Long Short-Term Memory (LSTM)

LSTM giải quyết vấn đề vanishing gradient của RNN cơ bản bằng cơ chế cổng (gate mechanism) với ba cổng chính:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (\text{Forget gate}) \quad (2.2)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (\text{Input gate}) \quad (2.3)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad (\text{Candidate}) \quad (2.4)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (\text{Cell state}) \quad (2.5)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (\text{Output gate}) \quad (2.6)$$

$$h_t = o_t \odot \tanh(C_t) \quad (\text{Hidden state}) \quad (2.7)$$

2.1.3 Bidirectional RNN

Bidirectional RNN xử lý chuỗi theo cả hai chiều (trái-sang-phải và phải-sang-trái), cho phép mỗi output phụ thuộc vào toàn bộ ngữ cảnh:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] \quad (2.8)$$

2.1.4 Transformer và Self-Attention

Transformer là kiến trúc được giới thiệu bởi Vaswani et al. (2017), sử dụng hoàn toàn cơ chế self-attention thay vì recurrence. Self-attention tính trọng số chú ý cho mỗi cặp vị trí trong chuỗi:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.9)$$

trong đó Q, K, V là các ma trận Query, Key, Value và d_k là kích thước key.

Multi-Head Attention cho phép mô hình học nhiều kiểu attention khác nhau:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2.10)$$

2.1.5 BERT (Bidirectional Encoder Representations from Transformers)

BERT là mô hình dựa trên Transformer encoder, được thiết kế để hiểu ngữ cảnh hai chiều (bidirectional context) của văn bản. BERT sử dụng hai nhiệm vụ huấn luyện: Masked Language Model (MLM) và Next Sentence Prediction (NSP), giúp mô hình nắm bắt ngữ nghĩa sâu của ngôn ngữ, vượt trội so với các mô hình sequence truyền thống.

Đặc điểm chính của BERT:

- **Bidirectional context:** Hiểu ngữ cảnh cả trước và sau mỗi từ, khác với LSTM chỉ xử lý tuần tự.
- **Fine-tuning:** Có thể tinh chỉnh trên tác vụ cụ thể với dữ liệu có nhãn.
- **Tokenization:** Sử dụng WordPiece tokenizer, hỗ trợ tối đa 512 tokens.

2.1.6 Mixture of Experts (MoE)

Mixture of Experts là kiến trúc kết hợp nhiều “expert networks” chuyên biệt, mỗi expert được huấn luyện để xử lý một loại pattern cụ thể. Một gating network quyết định expert nào sẽ xử lý mỗi input:

$$y = \sum_{i=1}^N g_i(x) \cdot E_i(x) \quad (2.11)$$

trong đó $g_i(x)$ là trọng số gating và $E_i(x)$ là output của expert thứ i .

Trong ngữ cảnh phân loại email, mỗi expert có thể chuyên biệt hóa cho một loại email khác nhau (email quảng cáo, email phishing, email cá nhân, v.v.), giúp tăng khả năng phân biệt spam.

2.1.7 Các kỹ thuật Regularization

Dropout: Ngẫu nhiên “tắt” một phần neurons trong quá trình huấn luyện với xác suất p :

$$\tilde{h} = m \odot h, \quad m_i \sim \text{Bernoulli}(1 - p) \quad (2.12)$$

Weight Decay (L2 Regularization): Thêm penalty vào loss function:

$$L_{\text{total}} = L_{CE} + \lambda \sum_i \|w_i\|_2^2 \quad (2.13)$$

Frozen Encoder: Đóng băng toàn bộ encoder, chỉ huấn luyện classifier head – đây là một hình thức regularization mạnh, giảm số tham số cập nhật xuống còn rất ít.

2.2 Các nghiên cứu liên quan

- **Naive Bayes & SVM:** Các phương pháp truyền thống sử dụng Bag-of-Words features, đạt hiệu quả tốt nhưng không nắm bắt được ngữ cảnh và thứ tự từ.
- **LSTM cho phát hiện spam:** Roy et al. (2020) áp dụng LSTM cho phát hiện spam, chứng minh rằng mô hình sequence có thể nắm bắt pattern ngữ cảnh hiệu quả hơn.
- **BERT cho phân loại văn bản:** Devlin et al. (2019) chứng minh BERT đạt state-of-the-art trên nhiều benchmark NLP nhờ khả năng hiểu ngữ cảnh hai chiều.
- **BERT MoE:** Kết hợp BERT với Mixture of Experts cho phép mô hình chuyên biệt hóa theo loại input, tăng khả năng phân loại.

Chương 3

Bài toán và dữ liệu

3.1 Mô tả bài toán

Phát hiện spam email là bài toán **phân loại nhị phân** (binary classification) trong xử lý ngôn ngữ tự nhiên.

Đầu vào (Input):

- Nội dung email bao gồm Subject + Body.
- Tiền xử lý: loại bỏ HTML tags, ký tự đặc biệt, URL, email addresses.
- BiLSTM: Tokenize và padding đến độ dài $L = 256$.
- BERT MoE: Tokenize bằng WordPiece đến độ dài $L = 512$.

Đầu ra (Output):

- Nhãn phân loại: Spam (1) hoặc Ham (0).
- Xác suất dự đoán $p \in [0, 1]$.


3.2 Dataset

3.2.1 Nguồn dữ liệu

Đồ án sử dụng dataset **Enron Spam** (`spam_ham_dataset.csv`) với các đặc điểm:

Bảng 3.1: Thông tin tổng quan dataset


Thuộc tính	Mô tả
Tổng số mẫu	5.170 emails
Số cột	4 (#, label, text, label_num)
Lớp Ham	3.672 mẫu (71%)
Lớp Spam	1.498 mẫu (29%)
Tỷ lệ Ham:Spam	$\approx 2.45:1$



Hình 3.1: Phân bố số lượng mẫu theo lớp Ham/Spam trong dataset


Nhận xét các khó khăn đặc thù của dataset:

1. **Mất cân bằng lớp:** Lớp Ham chiếm 71% so với Spam chỉ 29%. Tỷ lệ chênh lệch $\approx 2.45 : 1$ có thể khiến mô hình thiên lệch dự đoán lớp đa số. $\Rightarrow$ Giải pháp: sử dụng `class_weight` và `Weighted CrossEntropyLoss`.
2. **Biến thiên độ dài chuỗi:** Độ dài email dao động rất lớn (từ vài từ đến hàng nghìn từ).
3. **Nhiều dữ liệu:** Email chứa HTML tags, URL, email addresses, ký tự đặc biệt.
4. **Mẫu trùng lặp:** Cần loại bỏ để tránh rò rỉ dữ liệu (data leakage).



Hình 3.2: Phân bố độ dài văn bản theo số từ và Boxplot theo lớp

3.2.2 Tiền xử lý dữ liệu



Hình 3.3: Pipeline tiền xử lý dữ liệu email

Bảng 3.2: Phân chia tập dữ liệu (stratified split)

Tập dữ liệu	Số mẫu	Tỷ lệ Ham	Tỷ lệ Spam
Train	≈ 3.600	≈ 71%	≈ 29%
Validation	≈ 770	≈ 71%	≈ 29%
Test	≈ 770	≈ 71%	≈ 29%


Lưu ý quan trọng:

- BiLSTM sử dụng `clean_text` (đã lowercase, loại ký tự đặc biệt).
- BERT MoE sử dụng `text` gốc (BERT tokenizer tự xử lý).

Chương 4

Phương pháp đề xuất

4.1 Mô hình 1 – Baseline: BiLSTM + Embedding + Pooling




Hình 4.1: Kiến trúc mô hình 1 – BiLSTM Baseline

Mô tả kiến trúc:

1. **Input Layer:** Nhận chuỗi token ID có độ dài cố định 256.

2. **Embedding Layer:** Ánh xạ mỗi token thành vector 128 chiều. Ma trận embedding có kích thước 20.000×128 .
3. **SpatialDropout1D (0.2):** Dropout trên toàn bộ embedding channel để regularize.
4. **Bidirectional LSTM (128 units):** Xử lý chuỗi theo cả hai chiều, trả về sequences. Output dimension: 256×256 (128 mỗi chiều $\times 2$).
5. **GlobalMaxPooling1D:** Lấy giá trị lớn nhất từ mỗi feature dimension qua toàn bộ timesteps.
6. **Dense layers:** Hai lớp fully-connected (64 và 32 neurons) với ReLU activation.
7. **Dropout (0.5):** Regularization để chống overfitting.
8. **Output:** Một neuron với sigmoid activation cho phân loại nhị phân.

4.2 Mô hình 2 – Nâng cao: BERT MoE



Hình 4.2: Kiến trúc mô hình 2 – BERT MoE (Nâng cao)

Mô hình sử dụng: BERT MoE – mô hình kết hợp kiến trúc BERT Encoder với Mixture of Experts, được xây dựng và huấn luyện cho bài toán phát hiện spam email.

Các cải tiến so với Baseline:

1. **BERT Encoder:** Sử dụng kiến trúc Transformer encoder 12 layers, cho phép hiểu ngữ cảnh sâu hơn so với BiLSTM.
2. **Self-Attention toàn cục:** Hiểu ngữ cảnh toàn bộ email thay vì chỉ local context như LSTM.
3. **Mixture of Experts:** Nhiều expert networks chuyên biệt, mỗi expert xử lý một loại pattern email khác nhau.
4. **MAX_LEN = 512:** BERT hỗ trợ tối đa 512 tokens, giữ được nhiều thông tin hơn so với BiLSTM (256).
5. **Weighted CrossEntropyLoss:** Xử lý mất cân bằng dữ liệu trực tiếp trong loss function (thay vì chỉ dùng class_weight như BiLSTM).

4.3 Hàm mất mát và thuật toán tối ưu

4.3.1 Hàm mất mát

BiLSTM: Binary Cross-Entropy với class weight:

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N w_{y_i} [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (4.1)$$

BERT MoE: Weighted CrossEntropyLoss:

$$L_{WCE} = - \sum_{c=0}^1 w_c \cdot y_c \cdot \log(\hat{y}_c) \quad (4.2)$$

trong đó $w_0 \approx 0.70$ (Ham), $w_1 \approx 1.72$ (Spam).

4.3.2 Thuật toán tối ưu

Đề án so sánh hai optimizer cho mỗi mô hình:

Adam/AdamW:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (4.3)$$

BiLSTM: lr = 10^{-3} ; BERT MoE: lr = 2×10^{-5} với linear warmup.

SGD with Momentum:

$$v_t = \gamma v_{t-1} + \eta \nabla_{\theta} L(\theta), \quad \theta_{t+1} = \theta_t - v_t \quad (4.4)$$

BiLSTM: $lr = 10^{-2}$; BERT MoE: $lr = 5 \times 10^{-4}$.

4.3.3 Callbacks và Scheduler

- **EarlyStopping**: Dừng khi val_loss không cải thiện sau 3–5 epochs.
- **ReduceLROnPlateau** (BiLSTM): Giảm lr theo hệ số 0.5 khi stagnant.
- **Linear Warmup + Decay** (BERT): Warmup 10% total steps rồi linear decay.

Chương 5

Thực nghiệm và đánh giá

5.1 Thiết lập thí nghiệm

Bảng 5.1: Thiết lập thí nghiệm


Thuộc tính	Giá trị
Môi trường	Google Colab (GPU T4)
Framework	TensorFlow/Keras (BiLSTM) + PyTorch/HuggingFace (BERT MoE)
Epochs tối đa	30 (BiLSTM) / 10 (BERT MoE)
Batch size	32 (BiLSTM) / 8 (BERT MoE)
MAX_LEN	256 (BiLSTM) / 512 (BERT MoE)
Random seed	42

Danh sách 6 thí nghiệm:


1. BiLSTM + Adam + Dropout (0.5)
2. BiLSTM + SGD + Dropout (0.5)
3. BiLSTM + AdamW + Weight Decay (10^{-4})
4. BERT MoE + AdamW + Weighted Loss (Full Fine-tune)
5. BERT MoE + SGD + Weighted Loss (Full Fine-tune)
6. BERT MoE + AdamW + Frozen Encoder

5.2 Kết quả định lượng


5.2.1 Kết quả mô hình BiLSTM Baseline



Hình 5.1: So sánh kết quả 3 thí nghiệm BiLSTM Baseline



Hình 5.2: Confusion Matrix và Precision-Recall Curve – BiLSTM (Adam + Dropout)




(a) BiLSTM (SGD + Dropout)

(b) BiLSTM (Adam + Weight Decay)

Hình 5.3: Confusion Matrix các thí nghiệm BiLSTM còn lại

5.2.2 Kết quả mô hình BERT MoE


Kiểm tra mô hình trước huấn luyện (epoch 0):




Hình 5.4: BERT MoE – Confusion Matrix trước khi huấn luyện

Kết quả trước khi huấn luyện cho thấy mô hình chưa có khả năng phân loại tốt (Accuracy $\approx$ 64%, FP = 183, FN = 86), chứng tỏ quá trình huấn luyện là cần thiết để mô hình học được các đặc trưng phân biệt spam/ham.


Sau khi huấn luyện:



Hình 5.5: BERT MoE (AdamW + Weighted Loss) – Kết quả tốt nhất



Hình 5.6: Learning Curves – BERT MoE (AdamW + Weighted Loss)



(a) BERT MoE (SGD)

(b) BERT MoE (Frozen Encoder)


Hình 5.7: Confusion Matrix các thí nghiệm BERT MoE còn lại

5.2.3 Bảng so sánh tổng hợp

Bảng 5.2: So sánh kết quả tất cả các mô hình và thí nghiệm

Mô hình	Loại	Optimizer	Regularization	Acc	Prec	Recall	F1
BiLSTM	Baseline	Adam	Dropout=0.5	0.987	0.956	1.000	0.978
BiLSTM	Baseline	SGD	Dropout=0.5	0.988	0.977	0.982	0.979
BiLSTM	Baseline	AdamW	Weight Decay	0.985	0.968	0.982	0.975
BERT MoE	Nâng cao	AdamW	Weighted Loss	0.976	0.967	0.950	0.958
BERT MoE	Nâng cao	SGD	Weighted Loss	0.867	0.879	0.630	0.734
BERT MoE	Nâng cao	AdamW	Frozen Encoder	0.944	0.928	0.877	0.902

5.2.4 Biểu đồ so sánh tổng hợp



Hình 5.8: Biểu đồ so sánh tổng hợp và Radar chart – tất cả mô hình

5.3 Phân tích kết quả

5.3.1 So sánh Optimizer: Adam/AdamW vs SGD

- **BiLSTM:** Adam và SGD đều cho kết quả tốt ($\text{Acc} > 98.5\%$), với Adam hội tụ nhanh hơn trong các epoch đầu nhờ adaptive learning rate.
- **BERT MoE:** AdamW vượt trội hoàn toàn so với SGD. SGD chỉ đạt $\text{Recall} \approx 63\%$ – cho thấy SGD không phù hợp cho huấn luyện BERT vì learning rate cố định không tối ưu cho kiến trúc Transformer phức tạp.

5.3.2 So sánh Regularization


- **BiLSTM – Dropout vs Weight Decay:** Cả hai đều hiệu quả, Dropout (0.5) cho Recall cao hơn (100% vs 98.2%).
- **BERT MoE – Full Fine-tune vs Frozen:** Full fine-tune (AdamW) đạt $\text{Acc} 97.6\%$ vượt trội Frozen Encoder (94.4%). Frozen Encoder giữ nguyên trọng số encoder nhưng hạn chế khả năng thích ứng với dataset mới.

5.3.3 So sánh Baseline vs Nâng cao

BiLSTM Baseline bất ngờ cho kết quả rất tốt trên dataset này ($\text{Acc} \approx 98.7\%$, $\text{Recall} = 100\%$). BERT MoE (AdamW) đạt $\text{Acc} 97.6\%$ với $\text{FP} = 7$ (thấp hơn BiLSTM: $\text{FP} = 10$) nhưng $\text{FN} = 11$ (cao hơn BiLSTM: $\text{FN} = 0$).

Giải thích: Dataset Enron Spam tương đối nhỏ (≈ 5.000 mẫu) và có pattern spam rõ ràng. BiLSTM đủ khả năng học pattern này, trong khi BERT MoE – dù mạnh hơn về lý thuyết – cần nhiều dữ liệu hơn để phát huy toàn bộ tiềm năng của kiến trúc Transformer.

5.3.4 Phân tích lỗi điển hình



Hình 5.9: Phân tích lỗi: phân bố xác suất dự đoán và so sánh FP/FN giữa BiLSTM vs BERT MoE

Phân tích:

- **False Negatives (Spam → Ham):** Đây là lỗi nguy hiểm nhất. BERT MoE có 11 FN – spam email được viết tinh vi, giống email thông thường.
- **False Positives (Ham → Spam):** BERT MoE có 7 FP (ít hơn BiLSTM: 10 FP) – cho thấy Precision của BERT MoE cao hơn.
- **Trade-off:** Giảm ngưỡng threshold sẽ tăng Recall nhưng giảm Precision.

5.3.5 Giới hạn của mô hình

1. **Dataset giới hạn:** 5.170 mẫu là tương đối nhỏ cho Deep Learning, đặc biệt cho BERT.
2. **Chỉ sử dụng văn bản:** Không xét metadata (sender, IP, timestamp).
3. **Domain shift:** Mô hình huấn luyện trên Enron email (2000s) có thể không phù hợp với spam hiện đại.
4. **BERT MoE cần nhiều dữ liệu:** Kiến trúc Transformer phức tạp cần lượng dữ liệu lớn hơn để đạt hiệu quả tối ưu so với BiLSTM đơn giản hơn.

Chương 6

Kết luận và hướng phát triển

6.1 Kết luận

Đồ án đã hoàn thành các mục tiêu đề ra:

- **Phân tích và thiết kế:** Phân tích thành công bài toán phân loại spam email, nhận diện các thách thức (mất cân bằng lớp, nhiều HTML, độ dài biến thiên) và lựa chọn kiến trúc phù hợp.
- **Triển khai và thực nghiệm:** Triển khai đầy đủ pipeline từ tiền xử lý đến huấn luyện với 2 mô hình (BiLSTM baseline và BERT MoE nâng cao), 6 thí nghiệm so sánh optimizer và regularization. Đặc biệt, đã xử lý thành công vấn đề mất cân bằng dữ liệu bằng Weighted CrossEntropyLoss cho BERT MoE.
- **Đánh giá và vận dụng:** Đánh giá định lượng bằng Accuracy, Precision, Recall, F1-Score và PR Curve. Phân tích lỗi điển hình (FP/FN), so sánh chi tiết giữa BiLSTM và BERT MoE, và thảo luận giới hạn mô hình.

Kết quả nổi bật:

- BiLSTM Baseline đạt Accuracy 98.7%, Recall 100% – hiệu quả cao trên dataset nhỏ.
- BERT MoE cải thiện từ 64% (trước huấn luyện) lên 97.6% (sau huấn luyện) – chứng minh hiệu quả của quá trình training.
- Weighted Loss giúp giảm FP từ 44 xuống 7 cho BERT MoE.
- Adam/AdamW vượt trội SGD cho cả hai mô hình.

6.2 Hướng phát triển

1. **Mở rộng dataset:** Kết hợp thêm TREC Spam, Phishing dataset để tăng tính tổng quát.
2. **Multi-modal approach:** Kết hợp văn bản với metadata (sender, headers).

3. **Ensemble methods:** Kết hợp BiLSTM + BERT MoE qua voting/stacking.
4. **Data Augmentation:** Synonym replacement, back-translation.
5. **Triển khai production:** Đóng gói thành API (FastAPI) hoặc email client plugin.
6. **Thử nghiệm các BERT variants khác:** DistilBERT, RoBERTa, DeBERTa.
7. **Adversarial training:** Huấn luyện chống bypass spam filter.

Tài liệu tham khảo

- [1] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [2] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [3] D. Bahdanau, K. Cho, and Y. Bengio, “Neural Machine Translation by Jointly Learning to Align and Translate,” *Proceedings of ICLR*, 2015.
- [4] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” *Proceedings of ICLR*, 2015.
- [5] N. Srivastava et al., “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *JMLR*, vol. 15, pp. 1929–1958, 2014.
- [6] A. Vaswani et al., “Attention Is All You Need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [7] J. Devlin et al., “BERT: Bidirectional Encoder Representations from Transformers for Language Understanding,” *Proceedings of NAACL-HLT*, 2019.
- [8] N. Shazeer et al., “Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer,” *Proceedings of ICLR*, 2017.
- [9] P. K. Roy, J. P. Singh, and S. Banerjee, “Deep Learning to Filter SMS Spam,” *Future Generation Computer Systems*, vol. 102, pp. 524–533, 2020.
- [10] Y. Kim, “Convolutional Neural Networks for Sentence Classification,” *Proceedings of EMNLP*, 2014.
- [11] M. Abadi et al., “TensorFlow: A System for Large-Scale Machine Learning,” *Proceedings of OSDI*, 2016.
- [12] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *JMLR*, vol. 12, pp. 2825–2830, 2011.
- [13] T. Wolf et al., “Transformers: State-of-the-Art Natural Language Processing,” *Proceedings of EMNLP (System Demonstrations)*, 2020.